

TraceNex 视频模型接入操作手册

文档对象：运营人员 版本：v1.0（2026-05-10） 目标：在不写代码的前提下，让运营把已支持的视频厂商（厂商已经写好了适配器）接到 TraceNex 平台并对外售卖 关联：[docs/Weekly-upstream-sync-runbook.md](#)（合并节奏）、[OVERLAY.md](#)（自定义清单）

一、TraceNex 已支持的视频厂商一览

下面 8 家代码层面已经支持，运营在管理后台开通即可使用，不需要工程介入。

#	厂商	后台 ChannelType	主要模型	计费单位	输入类型	上游官网
1	快手 Kling (可灵)	50 (Kling)	kl <code>ing-v1</code> 、kl <code>ing-v1-6</code> 、kl <code>ing-v2-master</code>	按秒 (5/10s 档位)	文生视频 / 图生视频	https://klingai.com
2	生数 Vidu	52 (Vidu)	vidu <code>q2</code> 、vidu <code>q1</code> 、vidu <code>2.0</code> 、vidu <code>1.5</code>	按秒	文生视频 / 图生视频 / 首尾 帧 / 参考图	https://www.vidu.studio
3	字节即梦 Jimeng	51 (Jimeng)	j <code>imeng_vgfm_t2v_l20</code>	按秒	文生视频	火山引擎控制台
4	字节豆包 视频 Doubao Video	54 (DoubaoVideo) / 45 (VolcEngine)	d <code>oubao-seedance-1-0-pro-250528</code> 、 d <code>oubao-seedance-1-0-lite-t2v</code> 、d <code>oubao-seedance-1-0-lite-i2v</code> 、 d <code>oubao-seedance-1-5-pro-251215</code> 、d <code>oubao-seedance-2-0-260128</code> 、 d <code>oubao-seedance-2-0-fast-260128</code>	按秒	文生视频 / 图生视频	火山引擎控制台
5	阿里万相 Wanx	17 (Ali)	w <code>an2.5-i2v-preview</code> (有声推荐)、w <code>an2.2-i2v-flash</code> 、w <code>an2.2-i2v-plus</code> 、 w <code>anx2.1-i2v-plus</code> 、w <code>anx2.1-i2v-turbo</code>	按秒	图生视频 (部分模型支持有声)	https://dashscope.console.aliyun.com
6	MiniMax Hailuo (海螺)	35 (MiniMax)	M <code>iniMax-Hailuo-2.3</code> 、M <code>iniMax-Hailuo-2.3-Fast</code> 、 M <code>iniMax-Hailuo-02-T2V-01-Director</code> 、 T <code>2V-01</code> 、I <code>2V-01-Director</code> 、I <code>2V-01-live</code> 、 I <code>2V-01</code> 、S <code>2V-01</code>	按秒	文生视频 / 图生视频 / 主体 生视频	https://platform.minimaxi.com

#	厂商	后台 ChannelType	主要模型	计费单位	输入类型	上游官网
7	OpenAI Sora	55 (Sora) / 1 (OpenAI)	sora-2、sora-2-pro	按秒 (含分辨率档位)	文生视频 / 视频续写 (remix)	https://platform.openai.com
8	Google Veo (Vertex / Gemini API 两条通道)	41 (VertexAI) 或 Gemini channel	veo-3.0-generate-001、veo-3.0-fast-generate-001、veo-3.1-generate-preview、veo-3.1-fast-generate-preview	按秒 (含分辨率档位)	文生视频 / 图生视频	https://cloud.google.com/vertex-ai 或 https://aistudio.google.com

注：表格里的 ChannelType ID 是数据库 `channels.type` 字段的取值，运营在前端“渠道”页选下拉项时可以核对。模型名要逐字一致地填进 channel 的“模型”字段。

二、前端开通流程（管理员后台）

准备工作

- 获取上游 API key（每家做一次）：
 - 在厂商官网注册账号、完成实名 / 充值
 - 在控制台创建 API key（有些厂商叫“AccessKey + SecretKey”，参考下文“特殊认证”小节）
 - 把 key 保存到 1Password / 公司密码管理器，不要明文塞 IM
- 打开管理员后台：<https://api.aitracenex.com/console>（SG）或 CN 后台地址，登录管理员账号

步骤 1：创建渠道（Channel）

后台路径：渠道管理 → 添加渠道

字段	怎么填
类型	下拉选对应厂商（如 “Kling”、“Vidu”、“DoubaoVideo” 等）
名称	给运营自己看的备注，例如 kling-prod-1、vidu-backup
分组	现有分组（如 default）或新建一个独立分组（如 video-only，避免和文本模型混计费）
密钥（API Key）	厂商给的 token；多 key 用换行分隔可启用轮询
代理 / Base URL	留空走默认；如果走自建中转改这里。Vertex AI 的 region 通过模型名后缀自动识别，无需改
模型	复制本手册第一节“主要模型”那列里的模型名（完全一致），多模型用英文逗号分隔
测试模型	选一个最便宜的模型用来跑健康检查（避免“测试一次烧 ¥2”）

⚠️ 特殊认证小节： - 阿里万相 / 即梦：API key 字段填 `AccessKey:SecretKey`（用英文冒号拼接），系统会按 SigV4 风格签名 - Vertex AI：API key 字段填 service account JSON 文件整体内容（一行 base64 或多行 JSON 都可），需要 `aiplatform.endpoints.predict` 权限 - Gemini API（不是 Vertex）：直接填 Google AI Studio 给的 `AIza...` 字符串 - Kling：早期是 AccessKey + SecretKey 拼接；2026 之后官方有了 v2 token，直接填 token - MiniMax：填 group_id 和 api_key，格式为 `groupId|apiKey`（管道符分隔）

保存。系统会立即调用厂商 `/health` 或一个最小请求探活；成功 → 渠道状态变绿；失败 → 看红字提示，常见是 key 错或没充值。

步骤 2：配置模型价格（Model Price）

后台路径：运营设置 → 模型倍率 → 模型价格

视频模型不按 token 计费，必须用按次计费或按秒倍率。两种思路：

方案 A：固定每秒单价（推荐起步）

例： `kling-v2-master` 用户每秒 ¥0.50，平台按 0.7 折给运营，则填：

key	value	含义
<code>model_price</code> 中加	<code>kling-v2-master: 0.5</code>	用户每秒 ¥0.50
<code>model_ratio</code> 中加	<code>kling-v2-master: 0.7</code>	真实成本 = 0.7 × 用户价（用于内部毛利对账，不影响用户）

用户提交“5 秒视频” → 预扣 ¥2.50 → 完成后实际扣 ¥2.50（如果上游也确认 5 秒）

方案 B：按档位定价（更精细）

如果厂商不同分辨率/时长有阶梯价（Kling、Veo、Sora 都这样），用 `pkg/billingexpr`（阶梯计费表达式）：

```
input.duration <= 5 && input.resolution == "720p" : 0.30 * input.duration
input.duration <= 5 && input.resolution == "1080p" : 0.50 * input.duration
input.duration > 5 : 0.50 * input.duration
```

后台 → 模型价格 → 选择“动态计费 / 阶梯计费”，把表达式贴进去。

跨币种注意： `model_price` 默认单位是 `quota_per_unit`（一般是 ¥1 = 500000 quota）。检查后台“运营设置 → 通用 → 货币”，确保用户看到的单位和你预期一致（CN 站默认 ¥/RMB，SG 站可设 USD）。

步骤 3：分组配置（Group Ratio）

如果你想给 VIP / 内部测试用户更便宜的视频价：

后台路径：运营设置 → 分组倍率

分组	倍率	说明
<code>default</code>	1.0	普通用户
<code>vip</code>	0.8	VIP 八折
<code>internal</code>	0.0	公司内部用，不计费

不要给视频做 0.0 分组并放出去，0 元提交会被脚本拿去刷上游。`internal` 分组要绑定特定 token，用 `Token Group Ratio` 限制。

步骤 4：发个测试请求验证

在后台调试 / Playground 页（或自己用 curl）：

```
curl -X POST https://api.aitracenex.com/v1/video/generations \
-H "Authorization: Bearer sk-你的token" \
-H "Content-Type: application/json" \
-d '{
  "model": "klings-v1",
  "prompt": "A red panda sliding down a snowy mountain, cinematic 4k",
  "duration": 5
}'
```

返回 `{"task_id": "abc-123", "status": "submitted", ...}` →  成功提交，剩下交给后台轮询。

查询任务状态：

```
curl https://api.aitracenex.com/v1/video/generations/abc-123 \
-H "Authorization: Bearer sk-你的token"
```

`status` 会从 `submitted` → `in_progress` → `success`（带 `video_url`）或 `failure`（带 `fail_reason`）。

三、常见坑点（运营必读）

坑 1：视频生成时间长，前端轮询要做对

问题：Kling 生成一个 5s 视频实际要 1-3 分钟；Veo 8s 视频要 2-5 分钟；Sora 更慢。

正确做法：- 客户端不要每秒查一次 `GET /v1/video/generations/{task_id}` —— 命中限流就被 429。建议客户端按“5s 起步、指数退避到 30s”去查 - 后台已经有内置 polling 池每 15-60s 主动拉一次上游，用户客户端只是查 TraceNex 自己的 DB，不会真正打到上游 - 限流策略在 [运营设置](#) → [限流](#)，给 `relay_task` 路径设个合理的查询频次

坑 2：预扣费 vs 实际扣费不一致

问题：上游说“我给你 8 秒，不是你要的 10 秒” → 用户已经预扣了 10 秒的钱。

TraceNex 的处理：`AdjustBillingOnSubmit` 会基于上游回包修正；`AdjustBillingOnComplete` 会在任务完成时再修正一次。多扣的钱会自动退回用户余额，不用人工干预。

运营要做的：- 准备一份“申诉 SOP”：用户反映扣多了 → 直接看 [用量日志](#) 里那条 task 的 `quota` 列 vs `record consume log` 里的 `total_quota`，看是否两值不一致 → 如果一致说明是正常扣费，不一致看后台日志会有 `billing adjustment` 字样 - 永远不允许手动改 `user_quota` 字段。要返还就走“系统消息 + 充值码”补偿，留下审计痕迹

坑 3：上游突然涨价 / 下架模型

问题：厂商在没通知的情况下把 `klings-v1` 价格从 ¥0.20/s 改到 ¥0.30/s，TraceNex 还在按 0.20 收用户的钱 → 平台亏。

TraceNex 的应对：- 每周一通过 `scripts/channel-benchmark/py/fy-canary` 跑一次基线对比（参考 [Weekly-upstream-sync-runbook.md](#)）- 上游下架旧模型时，渠道会开始返回 4xx，TraceNex 把它标“自动禁用”。运营要在周报里检查“过去一周自动禁用的渠道”，及时补 channel - 价格变更要手动改，没有自动同步——这是故意的（避免上游恶意涨价瞬间把平台账户打穿）

坑 4：用户用错模型名

问题：用户写 "model": "kling" （少了版本号）→ 上游 400 错误 → 用户投诉“接口坏了”。

TraceNex 的应对： - 上游返回 400 时 TraceNex 会把错误透传给客户端，带上 request_id - 运营拿到投诉的 request_id → 后台 用量日志 搜 → 看 model_name 列就知道用户填的是什么 - 在产品文档（ /docs 页）里给用户列清楚每个模型的精确名字 + 价格 + 限制

坑 5：图生视频要传图，但参数怎么传？

TraceNex 统一用 OpenAI 兼容的 schema：

```
{
  "model": "kling-v1",
  "prompt": "the panda starts walking",
  "image": "https://example.com/panda.jpg",      // 单图：图生视频
  "image_tail": "https://example.com/panda2.jpg" // 可选：首尾帧
}
```

- 图片 URL 必须公开可访问（HTTPS；如果有签名 URL，时效要 ≥ 视频生成时长 + 30 分钟）
- 厂商不支持 base64 上传时，TraceNex 会在 4xx 错误里提示
- Vidu 支持 images 数组（参考图生视频，多张），其他厂商一般只支持单图

坑 6：Veo / Sora 走代理还是直连

模型	CN 站	SG 站
Veo (Vertex)	❌ 必须走代理（Vertex 在 CN 不可达）	✅ 直连
Veo (Gemini API)	❌ 必须走代理	✅ 直连
Sora	❌ 必须走代理	⚠️ 仍然推荐走代理（OpenAI 区域风控严）
Kling / Vidu / Hailuo / Wanx / Doubao / Jimeng	✅ 直连	⚠️ 走代理回国（国内厂商对海外 IP 风控严）

代理在渠道的 Base URL 字段配置（用自建的 https 中转 URL 替换厂商默认 URL）。

坑 7：内容审核 / NSFW 拦截

不同厂商的内容审核严格度天差地别：

厂商	审核严格度	拒绝时返回
Kling / 即梦 / 万相 / Hailuo	严（中国法规）	上游 4xx + 中文 reason
Doubao	严	上游 4xx
Veo / Sora	中（OpenAI/Google 政策）	4xx + 英文 reason
Vidu	中	4xx

运营要做的： - 用户投诉“被拒了” → 90% 是 prompt 触发审核 → 在 用量日志 看那条 task 的 fail_reason - 不要在你的产品里宣传“无限制 / 无审核”——会被上游永久封号 - 如果客户群体确实是合规但敏感（医疗、安全研究），优先选 Veo / Sora

坑 8：高并发会把上游打死

视频厂商的并发上限远低于文本模型：

厂商	默认并发上限	一旦超过
Kling	5	上游 429，等几分钟
Hailuo	3	上游直接拒 + 长冷却
Veo	10（按 GCP quota）	静默降优先级，任务排到几小时后
Sora	视账户档位	排队

运营要做的： - 在每个视频渠道开“渠道并发上限”（后台 → 渠道详情 → 高级），保守设置（如 Kling 设 3） - 如果产品要支撑大流量，多 channel 灰度负载均衡：建 2-3 个 Kling 渠道，分别用不同账户的 key，TraceNex 自动轮询

坑 9：发版后的回滚窗口

视频任务可能跨多个版本：

- 用户在 v1.7 提交了一个任务
- 几分钟后你 fab release v1.8，blue 容器从 v1.7 → v1.8
- 后台 polling 池继承 v1.8 代码去查任务状态

潜在问题：如果 v1.8 改了视频 adapter 的字段映射，老任务的 polling 可能返回错误状态。

TraceNex 的应对： - 视频 adapter 在 OVERLAY.md 里会标“breaking change”，发版前会做 staging 验证 - 24 小时蓝绿窗口期内如果出现“老任务卡住”，可以 fab rollback v1.7，老 polling 走回老代码

四、运营周检查清单

每周一花 15 分钟做一遍：

- ☐ 渠道健康：管理后台 → 渠道，看每个视频渠道的“最近测试时间 / 测试结果”，红的要查
- ☐ 额度水位：去厂商控制台，看每个 API key 的余额，< 1000 元 / \$200 立即充值
- ☐ 价格基线：跑一次 scripts/channel-benchmark/py/fy-canary audit，确认上游没偷换模型
- ☐ 失败率：后台 用量日志 筛 status = failure 过去 7 天，超过 5% 调查
- ☐ 平均响应时长：用 Prometheus 看 channel_benchmark_e2e_seconds{channel,model} 的 p95，超出 5 分钟的渠道考虑下线
- ☐ NSFW 拒绝率：失败原因里 content_filter / safety 的比例，超过 20% 检查产品 prompt 模板

五、新增不在列表里的厂商

如果运营遇到“客户问能不能接 Pika / Runway / Luma...”：

1. 先看是否有现成 adapter：relay/channel/task/<vendor>/，没有就需要工程
2. 提工单到工程，附上：
 - 厂商 API 文档链接
 - 模型列表 + 计费规则（每秒/每次/分辨率档位）
 - 是否有官方 OpenAI 兼容接口（有的话工作量减半）
 - 公司预计的月调用量（决定优先级）
3. 工程参考 Kling adapter （relay/channel/task/kling/adaptor.go，416 行）做样板，通常 2-3 个工作日能上线一个新厂商

六、联系人 & 应急

场景	找谁
渠道开不了 / key 不工作	工程支持
上游账单异常	财务 + 工程联合
用户大量投诉视频生成失败	工程值班 + 运营负责人
上游公告下架某模型	运营第一时间在产品端公告 + 工程下架 channel

工程值班：见公司 OnCall 表 运营值班：见公司运营值班表 蓝绿回滚命令（紧急）：

```
conda run -n fy-api-deploy fab rollback --target=cn --tag=v<上一个稳定版本>
conda run -n fy-api-deploy fab rollback --target=sg --tag=v<上一个稳定版本>
```

修订记录 - v1.0（2026-05-10）首次发布。覆盖 8 家已支持厂商。基于 v1.7-tracenex 镜像。